ML Canvas: MiBici, demanda, riesgo y patrones de estaciones

Equipo NN, TC5061 Diseñado con base en Dorard (2018)

Decisiones

- P1: cuántas bicicletas asignar por estación y zona y cuándo programar turnos.
- P2: qué estaciones visita primero el equipo de rebalanceo en cada bloque y si debe llevar o retirar bicicletas.
- P3: qué tipo de estación conviene abrir en cada zona y dónde ajustar capacidad.

Tarea de ML

- P1, regresión: salidas por estación y hora del día siguiente (horizonte de 1 a 24 h, información hasta el cierre del día anterior).
- P2, clasificación binaria: riesgo de vaciado o llenado por estación y bloque de 3 h del día siguiente.
- P3, clustering: grupos de estaciones según su patrón horario de uso.

Propuesta de valor

- Usuarios: operador del sistema (P1), equipo de rebalanceo (P2) y planeación urbana (P3).
- Menos estaciones vacías o llenas y rutas de rebalanceo más cortas.
- Planeación de flota con anticipación de un día.
- Expansión basada en evidencia de uso, no solo en ubicación.

Recolección de datos

- MiBici publica un CSV por mes; la ingesta (`dataset.py`) lo descarga, normaliza y versiona sin pasos manuales.
- Las etiquetas salen de los propios viajes (conteos y flujo neto); no requieren anotación.
- Al publicarse un mes nuevo se agrega a los datos y cambia la versión del manifiesto.

Fuentes de datos

- Viajes mensuales `datos_abiertos_AAAA_MM.csv`, 2025-01 a 2026-09: 7.89 M registros, 7.67 M limpios.
- Nomenclatura `nomenclatura_2026_09.csv`: 484 estaciones con capacidad y coordenadas.
- Calendario de festivos de México (paquete `holidays`).

Simulación de impacto

- Evaluación fuera de línea con partición temporal: entrenamiento 2025-01 a 2026-03, validación 2026-04 a 06, prueba 2026-07 a 09.
- P1: MAE, RMSE y WAPE (estación y municipio). P2: PR-AUC, precisión, exhaustividad y F1. P3: silueta, Davies-Bouldin y ARI de estabilidad.
- Criterio: superar al baseline en prueba.

Hacer predicciones

- P1 y P2: proceso por lotes cada noche, con los viajes hasta las 23:59, para todo el día siguiente.
- P3: se recalcula cada trimestre o cuando abren estaciones.
- Cómputo en CPU: minutos por corrida.

Aproximación del riesgo (P2)

- No hay inventario por estación. Se supone que el rebalanceo deja cada estación a media capacidad.
- Riesgo = 1 si en el bloque $|\text{llegadas} - \text{salidas}| \geq 0.5 \times \text{capacidad}$: la estación se vaciaría o llenaría.
- Tasa de positivos: 2.8%.

Construcción de modelos

- Baselines: ingenuo estacional de 7 días (P1), frecuencia de riesgo en 4 semanas (P2) y k-means con k = 4 sobre el perfil de salidas (P3).
- Candidatos: HistGradientBoosting Poisson (P1) y clasificador (P2); PCA + k-means con k elegido por silueta (P3).
- Reentrenamiento mensual; cada run queda en MLflow.

Variables (features)

- Calendario: hora, día de la semana, mes, fin de semana, festivo.
- Estación: capacidad, latitud, longitud, municipio.
- Rezagos de 24, 48, 168 y 336 h; promedio de la misma hora en 4 semanas; nivel del día anterior.
- P2: flujo neto y riesgo rezagados; tasa histórica.
- P3: proporción horaria de salidas y llegadas, peso del fin de semana, volumen y balance.

Monitoreo

Cada mes publicado se compara el pronóstico con los viajes reales (WAPE de P1 y PR-AUC de P2 frente a la línea base registrada en MLflow). La ingesta alerta si cambian el esquema, la codificación o el hash de un archivo ya publicado. Se vigilan la apertura o el retiro de estaciones y los cambios de capacidad, que alteran las etiquetas de P2 y los grupos de P3.